Nombre: Josselyn Fabiola Duarte Torrres

Carga y cruce de información de personas

Desarrollar un flujograma, donde se recibe un archivo Excel que contiene: nombre completo de persona (de la forma "Juan Antonio Garcia Hernandez"), número de DUI y otros campos demográficos.

Los nombres deben ser clasificados como: primer nombre, segundo nombre, tercer nombre, primer apellido, segundo apellido, apellido de casada.

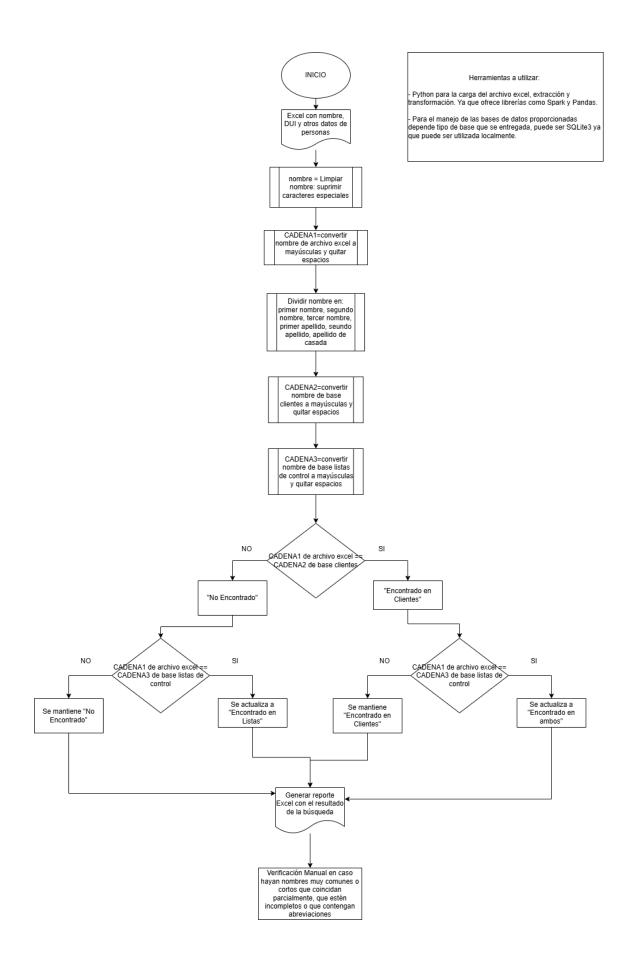
Se requiere un reporte Excel donde estén clasificados los registros del archivo original indicando si el registro fue encontrado en alguna base interna, ya sea como cliente de banco, como persona en lista de control, ambos casos, o indicar si no encontró en ninguna (registro nuevo). Realice operaciones de limpieza de cadenas para maximizar la efectividad del cruce masivo.

Cartera de clientes del banco: información general de los clientes.

Lista de control: información de personas con las que el banco no debería establecer relación.

Consideraciones:

- * Plantear que herramientas se utilizarían.
- * El nombre completo puede tener caracteres especiales, espacios en blanco, números, mayúsculas, minúsculas.
- * Usar expresiones regulares de ser necesario.
- * Indicar si se detecta alguna inconsistencia. Es decir, comente si existen escenarios ambiguos en el resultado del proceso que deban ser verificados manualmente.



Realizar el siguiente ETL

Realizar un ETL que cargue en una tabla el archivo "fuente.xlsx"

Se requiere un reporte Excel donde estén clasificados las personas basadas en la cartera donde encontró (tabla clientes, tabla lista_control) o indicar si no encontró en ninguna cartera.

Consideraciones:

- * Utilizar las tablas de la base sqlite proporcionada (ev_ing_dat.db)
- * Usar python, spark, sql, Power BI, según considere necesario.
- * Documentar la solución, los pasos del proceso.
- * Usa bitácora para el proceso (log y tabla de bitácora)
- * Versionar la solución usando git.
- * Calendarizar el programa para que se ejecute todos los 1° de cada mes a las 10 a.m.

Reporte esperado:

Nombre completo	Primer nombre	Segundo nombre	Tercer nombre	Primer apellido	Segundo apellido	Apellido de casada	Clasificación
Juan Antonio	Juan	Antonio		Garcia	Hernandez		Lista de
Garcia							control
Hernandez							
María Lopez de	María			López		De	Cartera de
Hernandez						Hernandez	Clientes
Sofía Gomez	Sofía			Gomez			No se
							encontró en
							las BD

Pasos:

1. Primero se creó el núcleo del ETL:

- Extracción

Ya que se solicita que el archivo 'fuente.xlsx' se almacene en una tabla, y por ello se cargara en la base 'ev_ing_dat.db'. Se hizo el proceso de leer el archivo conectar a la base (ya que ahí se creara la nueva tabla y ahí se encuentran las tablas de clientes y listas) y crear la tabla en caso no exista:

Cuando ya se tiene la tabla creada se procede a la carga.

```
#Limpiar tabla fuente
fuenteDltQry="DELETE FROM fuente"
cursor.execute(fuenteDltQry)
conn.commit()

seqDltQry="DELETE FROM sqlite_sequence WHERE name = 'fuente'"
cursor.execute(seqDltQry)
conn.commit()

#Cargar excel en tabla
for index, row in fuenteEx.iterrows():
    cursor.execute('''
    INSERT INTO fuente (nombre,documento)
    VALUES(?,?);
    ''',(row['Nombre'],row['documento']))
conn.commit()
```

- <u>Transformación</u>

Primero se hizo una limpieza de las cadenas de texto que se iban a comparar, haciendo uso de SQL y funciones de Python.

```
#Clientes
clientesGry="SELECT 'cliente' tabla,UPPER(REPLACE(TRIM(nombre1||nombre2||apellido1||apellido2||apellido_casada),' ','')) nombreCC,nombre
clientes=pnds.read_sql(clientesGry,conn)
clientes['nombreCC'] = clientes['nombreCC'].str.replace(r'[^a-zA-Z0-9\s]', '', regex=True)

#Listas
listasGry="SELECT 'lista' tabla,UPPER(REPLACE(TRIM(nombre),' ','')) nombreCC,nombre,UPPER(REPLACE(TRIM(documento),' ','')) documento FR
listas=pnds.read_sql(listasQry,conn)
listas['nombreCC'] = listas['nombreCC'].str.replace(r'[^a-zA-Z0-9\s]', '', regex=True)

#Fuente
fuenteQry="SELECT UPPER(REPLACE(TRIM(nombre),' ','')) nombreCC,nombre,'' Tercer_Nombre,UPPER(REPLACE(TRIM(documento),' ','')) documento
fuenteQry="SELECT UPPER(REPLACE(TRIM(nombre),' ','')) nombreCC,nombre,'' Tercer_Nombre,UPPER(REPLACE(TRIM(documento),' ','')) nombreCC,nombre,'' Tercer_Nombre,UPPER(REPLACE(TRIM(documento),' ','')) nombreCC,nombre,'' Tercer_Nombre,UPPER(REPLACE(TRIM(documento),' ','')) nombreCC,nombre,'' Tercer_Nombre,UPPER(REPLACE(TRIM(documento),' ','')) nombreCC,nombre,'' Tercer_Nombre,UPPER(REPLACE(TRIM(do
```

Luego se definió la función encargada de comparar las tablas y determinar si la persona existe en una de las bases: clientes o listas o si no fue encontrado.

```
#Busqueda de tabla fuente en tablas clientes y listas

def clasificar(row):
    if row['nombreCC'] in clientes['nombreCC'].values:
        return 'Cartera de Clientes'
    elif row['nombreCC'] in listas['nombreCC'].values:
        return 'Lista de Control'
    else:
        return 'No se encontro en las BD'

try:
    fuente['Clasificacion'] = fuente.apply(clasificar, axis=1)
```

- Carga

Ya que se debe generar un reporte Excel con el resultado, se usando la librería 'pandas' de Python de la siguiente forma:

```
#Formato y extraccion de Excel
fuente[['Primer_Nombre', 'Segundo_Nombre', 'Primer_Apellido', 'Segundo_Apellido', 'Apellido_de_Casada']]=fuente['nombre'].str.split(' ',ex
columnasExcel=['nombre', 'Primer_Nombre', 'Segundo_Nombre', 'Tercer_Nombre', 'Primer_Apellido', 'Segundo_Apellido', 'Apellido_de_Casada', 'Cl
fuenteExcel=fuente[columnasExcel].sort_values(by='Clasificacion', ascending=[True])
fuenteExcel.to_excel('clasificados.xlsx', sheet_name='datos', index=False)
registros=fuenteExcel.shape[0]
estado='0k'
logsClas('Carga', 'Se completo la carga de archivo excel')
except Exception as e:
logsClas('Error',f'Error en carga de archivo: {str(e)}')
estado=str(e)
```

Creación de bitácora y logs

Para el proceso de registrar en bitácora y generar logs se hizo lo siguiente:

- Logs

Se definió una función usando la librería logging que ofrece Python.

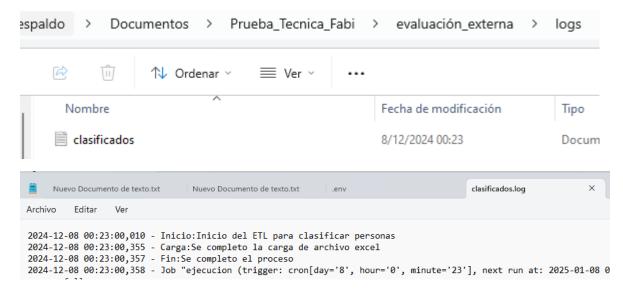
```
#Configurando logging
logging.basicConfig(filename='logs/clasificados.log', level=logging.INFO, format='%(asctime)s - %(message)s')
def logsClas(status,message):
    logging.info(f"{status}:{message}")
```

Y a lo largo del código se fue haciendo uso de esta función para registrar en el log los pasos y/o errores.

```
#log
logsClas('Inicio','Inicio del ETL para clasificar personas')

except Exception as e:
   logsClas('Error',f'Error en creacion y carga de tabla: {str(e)}')
   estado=str(e)
```

Mostrando un resultado como el siguiente.



- <u>Bitácora</u>

Para registro en bitácora se creo una tabla y se coloco el insert necesario para indicar el resultado de la ejecución.

```
finally:
    cursor.execute('''
        CREATE TABLE IF NOT EXISTS bitacora (
            idFuente INTEGER PRIMARY KEY AUTOINCREMENT,
            nombre VARCHAR(250),
            registros VARCHAR(20),
            estado VARCHAR(200),
            archivo VARCHAR(100),
            fecha VARCHAR(100)
    conn.commit()
    #Registro en bitacora
    cursor.execute('''
        INSERT INTO bitacora (nombre, registros, estado, archivo, fecha)
        VALUES(?,?,?,?,?);
        ''',(nombreProceso,registros,estado,archivo,fecha))
    conn.commit()
```

3. Calendarización

Para la calendarización se hizo uso de la librearía apschesuler de Python.

Se creo una función en la que se colocó todo el código a ejecutarse cada 1er día de cada mes a las 10 am.

```
#Programando ejecucion
def ejecucion():
    print("Inicio el cron")

nombreProceso='Clasificados'
    archivo=os.path.basename(__file__)
    fecha=datetime.now().strftime('%Y-%m-%d %H:%M:%S')
    registros=0

#Configurando logging
    logging.basicConfig(filename='logs/clasificados.log', level=logging.INFO, format='%(asctime)s - %(message)s')
    def logsClas(status,message):
        logging.info(f"{status}:{message}")

#log
```

Y se creo el objeto encargado de programar la ejecución.

```
scheduler = BlockingScheduler()
scheduler.add_job(ejecucion, 'cron', day=8, hour=0, minute=23)
scheduler.start()
```

4. Versionamiento usando GIT

Se preparo el repositorio local para hacer uso de GIT en el versionamiento del proyecto.

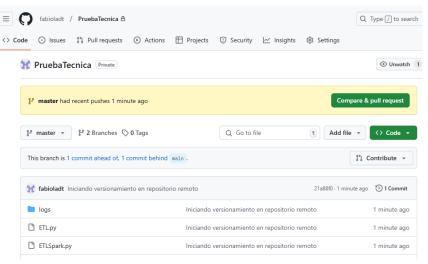
```
C:\Users\Diego\Documents\Prueba_Tecnica_Fabi\evaluación_externa>git init
Initialized empty Git repository in C:/Users/Diego/Documents/Prueba_Tecnica_Fabi/evaluación_externa/.git/
C:\Users\Diego\Documents\Prueba_Tecnica_Fabi\evaluación_externa>git config --global user.name "Fabiola Duarte"
C:\Users\Diego\Documents\Prueba_Tecnica_Fabi\evaluación_externa>git config --global user.email "josselynfabiola@gmail.com"
```

Se creo un repositorio remoto en GitHub

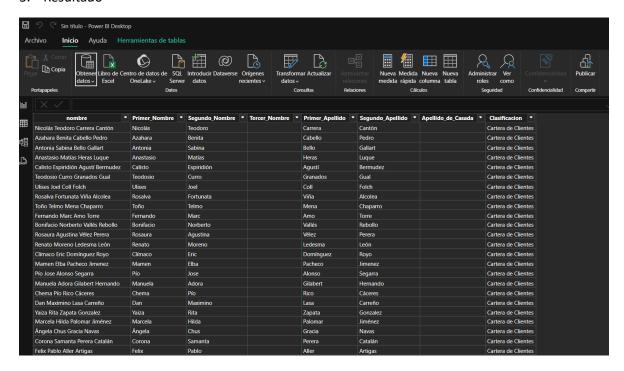
https://github.com/fabioladt/PruebaTecnica.git

Se asocio el repositorio local con el remoto

Y se hicieron los commits en el repositorio remoto



5. Resultado



Carga de listas de control ONU y OFAC.

Se tienen dos URLs y se requiere un proceso que cargue esta información en diferentes tablas relacionales según considere.

ONU: https://scsanctions.un.org/resources/xml/en/consolidated.xml

OFAC: https://www.treasury.gov/ofac/downloads/sdn.xml

- Analizar la estructura de los archivos xml y considerar que estos son actualizados de forma periódica.
- Crear las tablas y relaciones que considere necesario.
- Utilizar Python y sqlite.
- Compartir evidencias del funcionamiento, scripts usados (Python, sql, etc)
- Versionar el proceso usando git
- 1. Se ha creado una base en SQLite para este proceso, en dicha base se crearan las tablas necesarias.

```
def create db():
    conn=sqlite3.connect('listasOnuOfac.db')
    cursor=conn.cursor()
    cursor.execute('''
        CREATE TABLE IF NOT EXISTS "PersonasONU" (
        "DataID"
                    TEXT,
        "Version"
                    TEXT,
        "PrimerNombre" TEXT,
        "SegundoNombre" TEXT,
        "TipoLista" TEXT,
        "Referencia"
                        TEXT,
        "FechaLista"
                        TEXT,
        "Comentarios"
                        TEXT,
        "Titulo"
        "Designacion"
                        TEXT,
        "Nacionalidad"
                        TEXT,
        "TipoLista2"
                        TEXT,
```

2. Se ha definido una función para cargar primero el archivo de la ONU. Primero se hace una limpieza de las tablas

```
response=requests.get(url)
xmlEstructura=xmlET.fromstring(response.content)

conn=sqlite3.connect('listasOnuOfac.db')
cursor=conn.cursor()

cursor.execute("DELETE FROM PersonasONU")
cursor.execute("DELETE FROM PersonasONUAct")
cursor.execute("DELETE FROM PersonasONUAct")
cursor.execute("DELETE FROM PersonasONUAlias")
conn.commit()
```

Luego se hace un recorrido por el XML para extraer la información de cada persona

```
for INDIVIDUAL in xmlEstructura.findall('.//INDIVIDUAL'):

DataId=INDIVIDUAL.find('DATAID').text if INDIVIDUAL.find('DATAID') is not None else None

Version=INDIVIDUAL.find('VERSIONNUM').text if INDIVIDUAL.find('VERSIONNUM') is not None else None

PrimerNombre=INDIVIDUAL.find('FIRST_NAME').text if INDIVIDUAL.find('FIRST_NAME') is not None else None

SegundoNombre=INDIVIDUAL.find('SECOND_NAME').text if INDIVIDUAL.find('SECOND_NAME') is not None else None

TipoLista=INDIVIDUAL.find('UN_LIST_TYPE').text if INDIVIDUAL.find('UN_LIST_TYPE') is not None else None

Referencia=INDIVIDUAL.find('REFERENCE_NUMBER').text if INDIVIDUAL.find('REFERENCE_NUMBER') is not None else None

Fechalista=INDIVIDUAL.find('LISTED_ON').text if INDIVIDUAL.find('LISTED_ON') is not None else None

Comentarios=INDIVIDUAL.find('COMMENTS1').text if INDIVIDUAL.find('COMMENTS1') is not None else None

Titulo=INDIVIDUAL.find('.//ITILE/VALUE').text if INDIVIDUAL.find('.//TITLE/VALUE') is not None else None

Designacion=INDIVIDUAL.find('.//DESIGNATION/VALUE').text if INDIVIDUAL.find('.//DESIGNATION/VALUE') is not None else None

Nacionalidad=INDIVIDUAL.find('.//NATIONALITY/VALUE').text if INDIVIDUAL.find('.//LIST_TYPE/VALUE') is not None else None

TipoLista2=INDIVIDUAL.find('.//LIST_TYPE/VALUE').text if INDIVIDUAL.find('.//LIST_TYPE/VALUE') is not None else None
```

Y se procede al insert de cada registro extraído

cursor.execute("INSERT INTO PersonasONU (DataID, Version, PrimerNombre, SegundoNombre, TipoLista, Referencia, FechaLista, Comentarios, Titulo,
Nacionalidad, TipoLista2, PaisDir, TipoFechaNac, AnioNac, CiudadNac, PrivinciaNac, PaisNac, SortKey, SortKeyLastMod) \
VALUES (?,?,?,?,?,?,?,?,?,?,?,?,?,?,?,?,?,?)", (DataId, Version, PrimerNombre, SegundoNombre, TipoLista, Referencia, FechaLista, Comentar
Designacion, Nacionalidad, TipoLista2, PaisDir, TipoFechaNac, AnioNac, CiudadNac, PrivinciaNac, PaisNac, SortKey, SortKeyLastMod))

3. Se ha definido una función para cargar primero el archivo de la OFAC.

Se hace la lectura del archivo XML y limpieza de las tablas

```
response = requests.get(url)

# Verificar si la solicitud
if response.status_code == 200:
    print("Archivo XML descargado correctamente.")
    xmlEstructura = xmlET.fromstring(response.content)
    namespaces = {'ns': 'https://sanctionslistservice.ofac.treas.gov/api/PublicationPreview/exports/XML'}

    conn=sqlite3.connect('listasOnuOfac.db')
    cursor=conn.cursor()

    cursor.execute("DELETE FROM ListaOFAC")
    cursor.execute("DELETE FROM ListaAkaOFAC")
    cursor.execute("DELETE FROM ListaAddressOFAC")
    conn.commit()
```

Luego se recorre el XML para recuperar cada registro.

```
for sdnEntry in xmlEstructura.findall('.//ns:sdnEntry', namespaces):

Uid=sdnEntry.find('ns:uid', namespaces).text if sdnEntry.find('ns:uid', namespaces) is not None else None

for aka in xmlEstructura.findall('.//ns:addressList//ns:address', namespaces):

UidAddr=aka.find('ns:uid', namespaces).text if aka.find('ns:uid', namespaces) is not None else None

Address=aka.find('ns:address1', namespaces).text if aka.find('ns:address1', namespaces) is not None else None

City=aka.find('ns:city', namespaces).text if aka.find('ns:city', namespaces) is not None else None

PostalCode=aka.find('ns:postalCode', namespaces).text if aka.find('ns:country', namespaces) is not None else None

Country=aka.find('ns:country', namespaces).text if aka.find('ns:country', namespaces) is not None else None

cursor.execute("INSERT INTO ListaAddressOFAC (Uid,UidAddr,Address,City,PostalCode,Country) VALUES (?,?,?,?,?)",\

(Uid,UidAddr,Address,City,PostalCode,Country))

conn.commit()
```

4. Luego se define la función main() para la ejecución de las funciones anteriores.

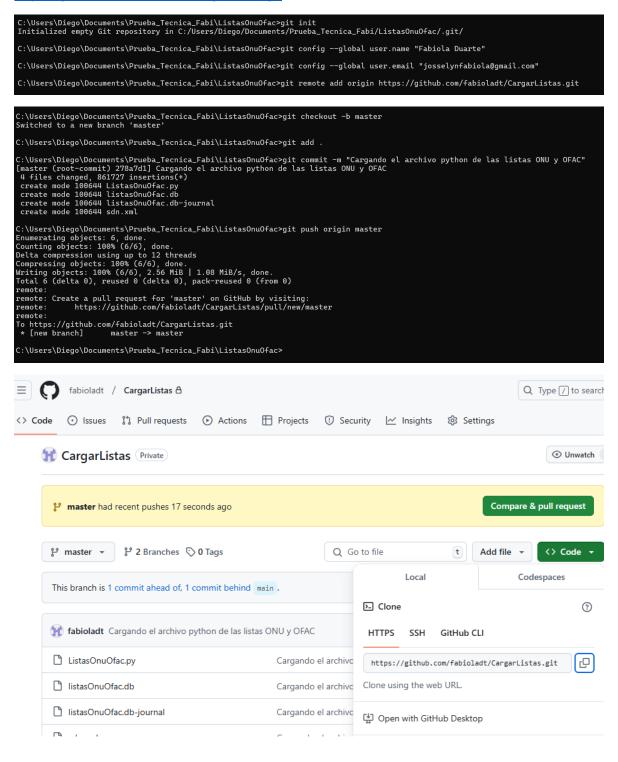
```
def main():
    create_db()
    url1='https://scsanctions.un.org/resources/xml/en/consolidated.xml'
    cargarXMLONU(url1)
    url2='https://www.treasury.gov/ofac/downloads/sdn.xml'
    cargarXMLOFAC(url2)

if __name__ == '__main__':
    main()
```

5. Se aplico versionamiento con Git

Se preparo el repositorio local y se vinculó con repositorio remoto. Y se subieron los cambios.

https://github.com/fabioladt/CargarListas.git



6. Resultado de la extracción.

Archivo ONU.

	DataID	Version	PrimerNombre	SegundoNombre	TipoLista	Referencia	FechaLista	Comentarios
	Filter	Filter	Filter	Filter	Filter	Filter	Filter	Filter
1	110447	1	MUHAMMAD	TAHER	Taliban	TAi.005	2001-02-23	Belongs to Andar tribe. Review
2	110554	1	ABDUL LATIF	MANSUR	Taliban	TAi.007	2001-01-31	Taliban Shadow Governor for Logar
3	110578	1	ABDUL KABIR	MOHAMMAD JAN	Taliban	TAi.003	2001-01-25	Active in terrorist operations in
4	110579	1	MOHAMMED	OMAR	Taliban	TAi.004	2000-04-12	Father's name is Ghulam Nabi, also
5	110580	1	SAYYED MOHAMMED	HAQQANI	Taliban	TAi.006	2001-01-31	Graduate of the Haqqaniya madrasa in
6	110896	1	SHAMS	UR-RAHMAN	Taliban	TAi.008	2001-02-23	Believed to be in Afghanistan/
7	110897	1	MOHAMMAD NAIM	BARICH	Taliban	TAi.013	2001-02-23	Member of the Taliban Military
8	110899	1	FAZL MOHAMMAD	MAZLOOM	Taliban	TAi.023	2001-02-23	Review pursuant to Security Council
9	110900	1	SAID AHMED	SHAHIDKHEL	Taliban	TAi.028	2001-02-23	In July 2003 he was in custody in
10	110901	1	MOHAMMAD	AHMADI	Taliban	TAi.031	2001-02-23	Believed to be in Afghanistan/
11	110912	1	ABDUL RAHMAN	ZAHED	Taliban	TAi.033	2001-01-25	Believed to be in Afghanistan/

	DataId	FechaActualizacion
	Filter	Filter
L	110447	2003-09-03
<u>)</u>	110554	2003-09-03
3	110578	2003-09-03
1	110579	2003-09-03
5	110580	2003-09-03

	DataId	Calidad	Alias
	Filter	Filter	Filter
1	110447	Good	Mohammad Taher Anwari
2	110554	Good	Abdul Latif Mansoor
3	110578	Good	A. Kabir
4	110579	NULL	NULL
5	110580	Good	Sayyed Mohammad Haqqani
6	110896	Good	Shamsurrahman
7	110897	Good	Mullah Naeem Barech
8	110899	Good	Molah Fazl

Archivo OFAC.

	Uid	lastName	sdnType	programList
	Filter	Filter	Filter	Filter
1	36	AEROCARIBBEAN AIRLINES	Entity	CUBA
2	173	ANGLO-CARIBBEAN CO., LTD.	Entity	CUBA
3	306	BANCO NACIONAL DE CUBA	Entity	CUBA
4	424	BOUTIQUE LA MAISON	Entity	CUBA
5	475	CASA DE CUBA	Entity	CUBA
6	480	CECOEX, S.A.	Entity	CUBA
7	535	CIMEX	Entity	CUBA
8	536	CIMEX IBERICA	Entity	CUBA

	Uid	UidAka	Туре	Category	lastName
	Fil	Filter	Filter	Filter	Filter
1	36	12	a.k.a.	strong	AERO-CARIBBEAN
2	36	57	a.k.a.	strong	AVIA IMPORT
3	36	219	a.k.a.	weak	BNC
4	36	220	a.k.a.	strong	NATIONAL BANK OF CUBA
5	36	471	a.k.a.	strong	COIBA
6	36	475	a.k.a.	strong	CRYMSA
7	36	477	a.k.a.	strong	COPROVA
8	36	478	a.k.a.	strong	COPROVA SARL

	Uid	UidAddr	Address	City	PostalCode	Country
	Fil	Filter	Filter	Filter	Filter	Filter
1	36	25	NULL	Havana	NULL	Cuba
2	36	129	Ibex House, The Minories	London	EC3N 1DY	Unit
3	36	199	Zweierstrasse 35	Zurich	CH-8022	Swit
4	36	200	Avenida de Concha Espina 8	Madrid	E-28036	Spain
5	36	201	Dai-Ichi Bldg. 6th Floor, 10-2 Nihombashi, 2	Tokyo	103	Japan
6	36	202	Federico Boyd Avenue & 51 Street	Panama City	NULL	Pana
7	36	247	42 Via Brasil	Panama City	NULL	Pana
8	36	271	NULL	NULL	NULL	Spain
9	36	272	NULL	NULL	NULL	Mexi
10	36	276	NULL	Panama City	NULL	Pana
11	36	317	Emerson No. 148 Piso 7	Mexico, D.F.	11570	Mexi
12	36	318	NULL	NULL	NULL	Spain
13	36	319	NULL	NULL	NULL	Pana